

Fine-tuning do TinyLlama 1.1B para Análise de Vulnerabilidades em Cibersegurança

Josean Mário Moreira Rodrigues¹, Wadson Fernandes Alves²

¹FACOM – Universidade Federal de Uberlândia (UFU)

{josean.rodrigues, wadson.alves}@ufu.br

Abstract. *This work investigates the application of Small Language Models (SLMs) in Explainable Artificial Intelligence (XAI) for Cybersecurity, aiming to reduce the dependency on high computational power. We propose a fine-tuning pipeline for the TinyLlama-1.1B model, utilizing the Gemini API to generate synthetic training data (threat interpretations) from Snort IDS logs. The model's effectiveness was evaluated through learning curves and ROUGE metrics. Results demonstrate that the SLM achieves stable convergence and produces coherent technical explanations, particularly with 512-token context windows. We conclude that using compact models is a viable and low-cost strategy that can assist analysts in the local interpretation of security incidents.*

Resumo. *Este trabalho investiga a aplicação de uma Small Language Models (SLMs) em Inteligência Artificial Explicável (XAI) para Cibersegurança, com o objetivo de reduzir a dependência de alto poder computacional. Propõe-se um pipeline de ajuste fino (fine-tuning) do modelo TinyLlama-1.1B, utilizando a API Gemini para gerar dados sintéticos de treinamento (interpretações de ameaças) a partir de logs do IDS Snort. A eficácia do modelo foi avaliada através de curvas de aprendizado e métricas ROUGE. Os resultados demonstram que a SLM atinge convergência estável e produz explicações técnicas coerentes, especialmente com janelas de contexto de 512 tokens. Conclui-se que o uso de modelos compactos é uma estratégia viável e de baixo custo, que pode auxiliar analistas na interpretação de incidentes de segurança locais.*

1. Introdução

Este trabalho aborda as tecnologias de *Large Language Model (LLM)* e *Intrusion Detection System (IDS)*. O LLM escolhido foi o *TinyLLama*, um modelo de baixo custo, que não exige uma máquina com recursos computacionais avançados ou modernos e roda até mesmo em computadores antigos. Tudo isso o torna ideal para sistemas que não podem arcar com o alto consumo de processamento.

As LLMs representam um grande avanço no ramo da inteligência artificial, sendo aplicadas em campos essenciais como educação, negócios e segurança cibernética. Esta tecnologia abre novas frentes de pesquisa sobre como diferentes LLMs podem ser utilizadas com a finalidade de proteger e monitorar sistemas de segurança [Calloway 2025].

Em segurança, os modelos de LLM ainda têm bastante limitações, mas apesar disso, este tópico continua atraindo grande interesse da comunidade. Devido a serem pré-treinados com uma grande quantidade de dados, as LLMs demonstram ter alta capacidade de executar tarefas simultaneamente e também de generalização. Os modelos

pré-treinados com logs de segurança, podem melhorar de forma relevante o campo de segurança cibernética [Bulut et al. 2024].

O refinamento das técnicas de ataque exigem, cada vez mais, atenção contínua e resposta por parte dos analistas de segurança. Que pode ser feita elevando o nível das regras, como também, expertise em segurança. Neste contexto, o trabalho humano pode ser reduzido, atribuindo algumas das tarefas a inteligência artificial. Uma LLM bem treinada pode automatizar várias tarefas que antes eram realizadas por mãos humanas [Daniel et al. 2025].

Este trabalho tem o objetivo de testar a capacidade do modelo *Tinyllama* em identificar corretamente *logs* do *Snort*. Enquanto outros trabalhos tem a proposta de incorporar modelos cada vez mais robustos de LLMs no campo de segurança cibernética, este segue o caminho inverso, buscando SLMs que possam ser utilizadas em ambientes críticos de maneira eficiente e sem que isso exija alto poder computacional. As principais contribuições deste trabalho são:

- Desenvolvimento de um *pipeline* de *fine-tuning* supervisionado: Integração do IDS *Snort* com a API *Gemini* para a geração automatizada de datasets de treinamento enriquecidos, permitindo a especialização de modelos menores.
- Validação de SLMs para interpretação de logs: Demonstração empírica de que o modelo *TinyLlama-1.1B*, quando ajustado corretamente, é capaz de atuar como assistente local de segurança, preservando a privacidade dos dados.
- Análise de desempenho e contexto: Identificação dos limites operacionais de modelos compactos, estabelecendo que uma janela de contexto mínima de 512 *tokens* é determinante para a coerência semântica das explicações de segurança.

2. Referencial Tecnológico

Esta seção aborda as principais tecnologias utilizadas para desenvolvimento deste trabalho.

2.1. *Snort* e base de dados

O *snort* é um dos principais sistemas de prevenção de Instrução (IPS). Além disso, é uma ferramenta de código aberto, o que permite aos seus usuários verificar o código fonte dela. O *snort* conta com uma grande variedade de regras, que ajudam a identificar atividades maliciosas na rede. O funcionamento da ferramenta para identificar ataques é por meio da análise de padrões nos pacotes trafegados. A partir disso, ele consegue emitir alertas para o analista de segurança.

A base de dados utilizada, disponível no repositório [Sconzo 2025], tem o propósito de facilitar o trabalho de analistas de segurança que desejam treinar modelos de *Machine Learning*. Esta base reúne dados que foram criados ou adicionados por outras fontes. O autor do repositório está empenhado em manter as bases atualizadas.

2.2. Arquitetura *Transformer*

A arquitetura *transformer* foi apresentada por [Vaswani et al. 2017]. Esta arquitetura é o pilar da IA moderna, sendo a base dos principais modelos conhecidos atualmente, como *Gemini*, GPT e *TinyLlama*. Esta arquitetura resolveu o principal problema de alguns dos

modelos anteriores, que processavam texto palavra por palavra, tornando o processo lento. O *transformer* tem o mecanismo de auto-atenção, que lhe permite processar todo o texto em paralelo, com isso gerando respostas mais eficientes.

2.2.1. Large Language Models (LLM)

LLM é um modelo de aprendizado profundo usado em inteligência artificial generativa. O objetivo final de um modelo de LLM é entender e gerar texto como um humano de forma aprofundada, sendo excelentes para traduzir textos. Os LLMs são treinados com larga quantidade de dados. Os seus bilhões de parâmetros permitem que eles tenham raciocínio apurado capturando padrões complexos na resolução de problemas. Podendo ser empregados em diversas áreas, que não necessariamente podem ter vínculo direto com tecnologia como o caso da segurança cibernética.

O *Gemini 2.5 Flash* é um dos modelos mais recentes de LLM lançado pela *Google*. Este modelo oferece recursos completos, como velocidade, custo-benefício, sendo o primeiro modelo flash com funcionalidades de raciocínio apurado. A interface de programação de aplicativos (API) é disponibilizada com algumas limitações em nível gratuito para desenvolvimento e testes pela *Google AI Studio*, o que torna este modelo a solução ideal para desenvolvedores que precisam de um modelo que seja de escalar e altamente inteligente.

2.2.2. Small Language Model (SLM)

SLM refer-se a modelos de LLM, que são projetados para serem compactos. Embora não tenham a capacidade de acumular larga quantidade de conhecimento como uma LLM, estes modelos possuem a vantagem de executar com eficiência tarefas específicas que exigem menos recursos que um modelo como o Gemini, podendo ser executada em *smartphones*, dispositivos *IoT* e outros sistemas que não possuem alta capacidade de processamento.

O *TinyLlama-1.1B-Chat-v1.0* é um modelo de SLM de código aberto que tem o objetivo de ser extremamente pequeno, possuindo 1,1 bilhão de parâmetros, sendo ideal para aplicações que exigem baixo custo computacional. Além disso, este modelo utiliza a mesma arquitetura e tokenizador do Llama 2, o que o torna compatível com o vasto ecossistema de ferramentas construídas da família Llama.

2.3. Supervised Fine-Tuning (SFT)

O SFT ou Ajuste Fino Supervisionado é o processo de especializar um modelo de LLM/SLM em uma tarefa específica. Esta técnica consiste em pegar um modelo genérico e treiná-lo com um dataset menor e de alta qualidade, assim o especializando. Ele não é alimentado com texto bruto, mas com pares exatos de “entrada-saída” ou “instrução-resposta”. Isto faz com o que modelo consiga seguir comandos e se comportar como um assistente especialista.

O *Parameter-Efficient Fine-Tuning PEFT* ou Ajuste Fino Eficiente de Parâmetros é um conjunto de técnicas que permite tornar o ajuste fino de modelos de LLM mais

eficientes. O PEFT não faz o retreino de todos os bilhões de parâmetros, em vez disso, ele congela o modelo original e foca o treino em um número pequeno de parâmetros [Han et al. 2024].

Adicionalmente, o *Low-Rank Adaptation (LoRA)* ou Adaptação de Baixo Rank treina acelera o treinamento por meio do treinamento de adapters que são perturbações em matrizes de pesos selecionados. Há indícios de que o LoRa apresenta desempenho equivalente ou superior ao retreino completo [Biderman et al. 2024].

2.4. Recall-Oriented Understudy for Gisting Evaluation (ROUGE)

Para quantificar a qualidade das explicações geradas pelo modelo de Inteligência Artificial, utilizou-se o conjunto de métricas ROUGE. Amplamente adotado em tarefas de Processamento de Linguagem Natural (PLN), o ROUGE avalia a similaridade entre a saída gerada pelo modelo e uma ou mais referências humanas (*Ground Truth*), focando principalmente na revocação (*Recall*). Diferente de sistemas de detecção de intrusão (IDS) clássicos, onde a métrica é binária (detectou/não detectou), em XAI o objetivo é a qualidade da justificativa. Por isso, métricas de similaridade textual como o ROUGE são mais apropriadas do que métricas de classificação como Acurácia ou *F1-Score* para esta etapa específica do trabalho. [Yuan et al. 2024], [Hu and Zhou 2024].

3. Trabalhos Relacionados

O trabalho de [Bulut et al. 2024] aborda uma SLM focada em *logs* de segurança. O SecEncoder é projetado para encontrar padrões únicos nos *logs* que ele foi treinado. Os resultados indicam que este modelo supera modelos mais robustos como o BERT-large, DeBERTa-v3-large e outros modelos que são pré-treinados principalmente com linguagem natural e que conseguem resolver uma ampla variedade de tarefas.

O trabalho de [Daniel et al. 2025] investiga a capacidade de 3 modelos de LLM em traduzir 973 alertas do *Snort*. As LLMs utilizadas foram ChatGPT, Claude e Gemini. A técnica utilizada consiste em injetar um prompt e o alerta bruto na entrada e com isso receber uma saída traduzida que facilite a leitura do analista de segurança. Embora os resultados dos LLMs fossem eficientes e escaláveis, os modelos mais tradicionais de *machine learning* conseguem superar a precisão dos modelos de LLM neste quesito.

O trabalho de [Mitra et al. 2025] apresenta um *framework* denominado *FALCON*. Este *framework* é capaz de gerar regras do *Snort* em tempo real. Além disso, ele também se destacou na geração de regras, com uma média de 95% de precisão validada por avaliação qualitativa e com 84% de concordância entre os avaliadores. Os resultados obtidos evidenciam a importância da mineração de dados em conjunto com LLMs.

O trabalho de [Habibzadeh et al. 2025] apresenta um *survey* sobre o emprego de LLMs para automatizar o grande volume de dados em um *Security Operation Center* (SOC). Segundo o autor, este trabalho tem grande importância, pois oferece a gerentes de SOC e pesquisadores uma ampla visão sobre a integração de LLMs com o SOC. Além disso, é um dos primeiros trabalhos a abordarem com riqueza de detalhes o tema.

O trabalho de [Feng and Sakurai 2025] aborda um *survey* que expõe a evolução dos sistemas de IDS. Foram analisados métodos convencionais, como o de redes neurais. São explorados os pontos fortes e fracos de cada método empregados em IDS. O autor

aponta que as LLMs apresentam novos benefícios em comparação com os métodos anteriores, porém, não é viável treinar uma LLM do início, o que se faz necessário abordagens como a de *fine-tuning*.

O trabalho de [Meng et al. 2025] apresenta um *framework* denominado RHINO. O RHINO faz a análise de ataques baseada em LLMs. O sistema funciona decompondo a análise em 3 partes. A primeira parte interpreta os *logs* com dados brutos e com isso fornece as entradas para a segunda parte. A segunda parte instrui o LLM a simular especialistas de segurança. Por fim, a terceira parte faz a validação, cruzando com dados do MITRE, para retificar possíveis alucinações do LLM. O RHINO alcançou altas precisiões com variações entre 86% e 88%.

O nosso trabalho focou na utilização modelos de baixo custo para a análise e interpretação de *logs* do SNORT. Utilizamos o modelo *TinyLlama-1.1B*. Este modelo é interessante pois ele entende a língua portuguesa, não sendo necessário treiná-lo também para aprender português e assim oferecer os *insights* dos *logs* em português. Além disso, este modelo possui licença Apache 2.0, o que permite que qualquer pessoa possa usar, modificar, distribuir e até mesmo comercializar.

3.1. Discussão

Trabalho	Utiliza SLM	Interpretação de logs Snort com LLM/SLM
[Bulut et al. 2024]	Sim	Não
[Daniel et al. 2025]	Não	Sim
[Mitra et al. 2025]	Não	Sim
[Habibzadeh et al. 2025]	Não	Não
[Feng and Sakurai 2025]	Não	Não
[Meng et al. 2025]	Não	Não
Nosso trabalho	Sim	Sim

Tabela 1. Tabela de comparação entre os trabalhos.

A análise comparativa apresentada na Tabela 1 revela uma lacuna importante na literatura atual quanto ao uso de modelos otimizados. Observa-se que apenas o estudo de [Bulut et al. 2024] utiliza a abordagem de SLM, porém sem aplicá-la especificamente ao processamento de *logs* do Snort. Por outro lado, embora os trabalhos de [Daniel et al. 2025] e [Mitra et al. 2025] realizem a interpretação de dados do Snort, ambos o fazem recorrendo a modelos de LLM, que demandam maior poder computacional. Nesse cenário, o presente trabalho se diferencia como a única solução que integra o uso de SLM voltado especificamente para a interpretação de *logs* do Snort, unindo a eficiência de modelos menores à especialização necessária para a análise de segurança de rede.

4. Proposta

A arquitetura proposta para integrar modelos de detecção de intrusão está organizada em duas etapas principais: a fase de treinamento e a fase de teste. Conforme ilustrado na Figura 1, na fase de treinamento, inicia-se o processo com um conjunto de dados de segurança, contendo descrições de ameaças, assinaturas, regras e exemplos de incidentes em formato de texto simples.




Figura 1. Fases do Projeto.

Este material é pré-processado e transformado em *logs* no estilo *Snort* (como arquivos *JSON*), formando o “Conjunto de Dados de *Logs Snort*”. A partir desses *logs*, a *API Gemini* é acionada para produzir *insights* em linguagem natural para cada evento, descrevendo o tipo de ameaça e sugerindo ações para mitigação. Estes insights gerados pela API serão usados no treinamento do *TinyLlama*, um SLM projetado para operar em ambientes com recursos limitados.

Conforme representado na Figura 1, o modelo *Gemini* atua como um “professor”, fornecendo interpretações detalhadas e bem estruturadas, que são convertidas em pares de entrada/saída para o SLM *TinyLlama*. Isso permite que o *TinyLlama* aprenda, a partir de atributos de *log*, a detectar padrões de ataque e produzir respostas explicativas e recomendações que se aproximam da qualidade de um LLM baseado em nuvem.

Na fase de teste, mostrada na seção inferior da Figura 1, o mesmo Conjunto de Dados de *Logs Snort* é fornecido em paralelo tanto ao *TinyLlama* quanto à *API Gemini*. Cada modelo gera independentemente sua interpretação do evento, fornecendo *insights* sobre a ameaça detectada e sugerida ações para mitigação. Esses resultados são então comparados para avaliar o quanto o SLM se aproxima do raciocínio e interpretabilidade do LLM, tanto em termos de identificação de ameaças quanto de clareza das ações recomendadas.

E na última fase, os *insights* produzidos pelos dois modelos podem ser incorporados ao fluxo de trabalho do analista de segurança, oferecendo para cada alerta explicações e orientações em linguagem natural. Ao comparar o *TinyLlama* e a *API Gemini* usando *logs Snort* idênticos, a abordagem fornece evidências baseadas na experiência da viabilidade de implantar SLMs em ambientes onde a privacidade, a latência ou as restrições computacionais são limitados e não possibilitam o uso de grandes modelos baseados em nuvem, mantendo níveis satisfatórios e significativos de explicabilidade e de suporte à decisão.

5. Metodologia

A metodologia experimental adotada neste trabalho foi delineada com o objetivo de instanciar, executar e avaliar empiricamente a arquitetura proposta na seção anterior, considerando um cenário realista de análise de eventos de segurança cibernética. Todas as etapas experimentais foram conduzidas em ambiente controlado, garantindo reprodutibilidade e consistência dos resultados, desde a preparação dos dados até a análise das métricas de desempenho.

Os experimentos foram executados em ambiente computacional baseado em *Google Colab*, permitindo a padronização do ambiente de execução e o uso de bibliotecas atualizadas sem dependência de infraestrutura local. A implementação foi realizada em *Python*, com suporte da biblioteca *PyTorch* para o ajuste fino e inferência do modelo de linguagem, assegurando flexibilidade no controle dos hiperparâmetros e no monitoramento do processo de treinamento.

A etapa inicial consistiu na seleção e no tratamento dos registros de segurança gerados pelo sistema de detecção de intrusão *Snort*. Os *logs* foram organizados em formato textual estruturado, preservando os atributos essenciais para caracterização dos eventos, e utilizados como instâncias de entrada no processo experimental. Esses registros serviram tanto para a geração dos dados de treinamento supervisionado quanto para a fase de avaliação comparativa entre modelos.

O ajuste fino do modelo *TinyLlama-1.1B* foi conduzido por meio de *Supervised Fine-Tuning*, utilizando um conjunto de pares de entrada e saída previamente construído. O treinamento foi realizado ao longo de múltiplas épocas, com divisão explícita entre dados de treinamento e validação, permitindo acompanhar a evolução da função de perda e identificar o ponto de convergência do modelo. Essa estratégia possibilitou avaliar a capacidade de generalização do SLM, aspecto crítico em aplicações de explicabilidade voltadas à segurança cibernética.

Concluída a fase de treinamento, o modelo ajustado foi submetido a testes utilizando *logs* não vistos durante o processo de ajuste fino. As saídas geradas pelo *TinyLlama* foram então comparadas às interpretações produzidas pelo modelo de referência baseado em nuvem, considerando exclusivamente o conteúdo textual das explicações. Essa comparação teve como finalidade mensurar o grau de proximidade semântica e estrutural entre as respostas, sem recorrer a métricas tradicionais de classificação, uma vez que o foco do estudo reside na qualidade explicativa das saídas.

A avaliação experimental foi estruturada a partir de duas perspectivas complementares. A primeira concentrou-se na estabilidade e eficiência do processo de aprendizado, analisada por meio das curvas de perda de treinamento e validação. A segunda perspectiva avaliou a qualidade das explicações geradas pelo modelo, utilizando métricas *ROUGE* para quantificar a similaridade entre os textos produzidos e as referências técnicas adotadas. Essa abordagem permitiu correlacionar a convergência do modelo com seu desempenho explicativo, fornecendo evidências empíricas sobre a viabilidade do uso de modelos compactos em cenários de apoio à decisão em segurança cibernética.

6. Resultados

Esta Seção apresenta e discute os resultados obtidos no processo de ajuste fino do *TinyLlama-1.1B*, com o objetivo de especializá-lo na tarefa de geração de explicações inteligíveis para eventos de segurança cibernética.

A validação de modelos de Inteligência Artificial Explicável (XAI) exige uma abordagem de avaliação dupla. Não basta apenas que o modelo convirja matematicamente; é necessário que a saída textual seja coerente, tecnicamente precisa e útil para o analista de segurança.

A análise de desempenho foi estruturada em duas frentes complementares para validar a eficácia do modelo. A primeira foca na eficiência do aprendizado, utilizando as curvas de *Loss* (treino e validação) para garantir que o modelo desenvolveu a capacidade de generalizar sobre ameaças e vulnerabilidades, evitando o ajuste excessivo aos dados. Paralelamente, a qualidade da geração textual é aferida por meio das métricas *ROUGE*, que comparam a similaridade entre as explicações geradas pela IA e as referências técnicas esperadas. A seguir, detalham-se esses indicadores, evidenciando a correlação entre o tempo de treinamento e a precisão das respostas fornecidas.

6.1. Análise da Convergência do Treinamento

Inicialmente, observamos o comportamento do modelo durante as épocas de treinamento para verificar a estabilidade do aprendizado e a capacidade de generalização.




Figura 2. Desempenho do Modelo ao Longo das Épocas (*Loss* de Treinamento vs. Validação)

O gráfico exibido na Figura 2 apresenta a evolução da função de perda (*Loss*) ao longo de 6 épocas. O eixo horizontal marca a progressão temporal, enquanto o eixo vertical indica o valor numérico da perda.

A análise das curvas revela que, nas duas primeiras épocas, ocorre uma convergência inicial rápida, com ambas as perdas caindo de 0,80 para a faixa de 0,70. Esse comportamento sinaliza que o modelo absorveu os padrões fundamentais do *dataset* logo no início do ajuste de pesos, demonstrando eficiência no aprendizado primário.

Contudo, a partir da terceira época, surge um ponto de divergência: enquanto a *Loss* de treinamento mantém uma queda agressiva até atingir aproximadamente 0,55 na sexta época, a *Loss* de validação desacelera e estabiliza em torno de 0,65. Esse distanciamento entre as linhas nas fases finais sugere o início de um quadro de *overfitting* (sobreajuste). No contexto de XAI aplicado à Cibersegurança, esse fator é crítico, pois o modelo deve ser capaz de explicar ameaças que não são meras cópias dos dados de treino. Diante desse cenário, os indicadores apontam que o equilíbrio ideal entre aprendizado e generalização foi atingido próximo à Época 4, ponto que confere maior robustez técnica ao modelo.

Uma vez validada a estabilidade do treinamento, avaliamos a qualidade do texto gerado submetendo o modelo a diferentes configurações de comprimento de saída (*Max New Tokens*).




Figura 3. Desempenho do Modelo em Diferentes Comprimentos de Saída (ROUGE-1, ROUGE-2, ROUGE-L)

A análise visual da Figura 3 revela um comportamento não linear na qualidade da geração conforme o limite de *tokens* é alterado. Inicialmente, observa-se a dominância da métrica *ROUGE-1*, que apresenta os valores mais altos em todos os cenários e atinge um pico superior a 0,40 com 512 *tokens*. Esse desempenho demonstra a eficácia do modelo em recuperar terminologias técnicas essenciais, como nomes de ataques e protocolos.

Por outro lado, nota-se uma queda acentuada de desempenho quando o limite é fixado em 128 *tokens*, o que representa um ponto crítico para aplicações de XAI. O truncamento das respostas nesse patamar impede o desenvolvimento do raciocínio necessário, resultando em explicações incompletas que prejudicam a similaridade com a referência técnica. Essa tendência é revertida com o aumento para 256 e 512 *tokens*, onde ocorre uma recuperação consistente. A métrica *ROUGE-L*, que reflete a estrutura e a coesão das frases, acompanha essa evolução, sugerindo que o *TinyLlama* demanda maior espaço para elaborar explicações estruturadas, fator fundamental para garantir a transparência em sistemas de defesa.

6.2. Correlação entre Estabilidade e Explicabilidade

A análise conjunta das métricas de perda e de qualidade de texto (*ROUGE*) oferece uma visão mais global sobre a eficácia do experimento.

O gráfico da Figura 3 demonstrou que o modelo atingiu uma convergência satisfatória por volta da 4ª época, indicando que ele internalizou com sucesso os padrões lógicos dos dados de segurança. No entanto, a análise das métricas *ROUGE* revela que essa “internalização do conhecimento” só se traduz em explicações de alta qualidade quando o modelo possui liberdade de geração suficiente.

O desempenho superior observado quando o parâmetro *Max New Tokens* é definido em 512 valida a hipótese de que a explicabilidade em segurança cibernética não pode ser resumida excessivamente. Para que a IA seja “Explicável” (XAI) e confiável para um operador humano, ela necessita de uma janela de contexto ampla para articular detalhadamente a natureza de uma ameaça ou vulnerabilidade.

7. Conclusão

O presente trabalho cumpriu o objetivo inicial de avaliar a viabilidade técnica do modelo *TinyLlama-1.1B* como uma ferramenta de Inteligência Artificial Explicável aplicada à segurança cibernética. Em resposta à crescente complexidade das ameaças digitais e à necessidade de reduzir a carga sobre o analista humano, a pesquisa demonstrou que a SLM oferece uma alternativa eficiente e de baixo custo computacional frente a grandes modelos comerciais baseados em nuvem.

O cumprimento dos objetivos específicos permitiu a construção de um *pipeline* funcional, iniciando na filtragem e estruturação dos *logs* do *Snort* e chegando ao uso da API *Gemini* como “professor” para a geração de dados de treinamento. O processo de *fine-tuning* comprovou que o *TinyLlama* é capaz de internalizar o vocabulário técnico e a lógica de detecção de intrusão, apresentando uma convergência estável de aprendizado por volta da 4ª época, o que reduz os riscos de *overfitting* e o custo energético do treinamento.

A análise dos resultados, fundamentada nas métricas *ROUGE* e na observação das curvas de *Loss*, evidenciou que a capacidade explicativa do modelo está diretamente ligada à janela de contexto disponível.

Conclui-se que, para tarefas de XAI onde a precisão técnica é determinante, o modelo demanda liberdade de geração (configuração de 512 *tokens* de saída) para articular justificativas coerentes, superando as limitações observadas em respostas truncadas. Portanto, o estudo valida a hipótese de que modelos compactos podem operar localmente em ambientes críticos, permitindo o acesso a ferramentas avançadas de defesa sem a exigência de hardwares caros de alta performance.

7.1. Trabalhos Futuros

A partir das descobertas e das limitações identificadas neste estudo, propõem-se caminhos para pesquisas futuras que aprofundem a viabilidade prática da solução. Uma direção relevante envolve a validação *human-in-the-loop*, por meio de experimentos qualitativos em que analistas de segurança avaliem, em testes “às cegas”, a utilidade e a clareza das

explicações do *TinyLlama* em comparação às saídas do *Gemini*. Adicionalmente, a expansão para novos cenários é fundamental para testar a generalização do modelo frente a *logs* de ataques *zero-day* e sua integração com outros sistemas de IDS, como *Suricata* ou *Zeek*, ampliando o escopo para além do *Snort*.

No campo da otimização, a investigação de técnicas de quantização (4-bits ou 8-bits) apresenta-se como um passo estratégico para viabilizar a implantação do modelo em dispositivos de borda (*edge computing*), como *firewalls* e roteadores. Por fim, projeta-se a evolução do modelo para a geração automática de regras de bloqueio, permitindo que a IA não apenas explique o incidente, mas também sugira contramedidas imediatas para o *Snort*, automatizando o ciclo completo de resposta a incidentes de segurança.

Referências

- Biderman, D., Portes, J., Ortiz, J. J. G., Paul, M., Greengard, P., Jennings, C., King, D., Havens, S., Chiley, V., Frankle, J., et al. (2024). Lora learns less and forgets less. *arXiv preprint arXiv:2405.09673*.
- Bulut, M. F., Liu, Y., Ahmad, N., Turner, M., Ouahmane, S. A., Andrews, C., and Greenwald, L. (2024). Secencoder: Logs are all you need in security. *arXiv preprint arXiv:2411.07528*.
- Calloway, C. (2025). Why do different llms give different answers to the same question? model uncertainty and variability in llm-based intrusion detection systems ranking.
- Daniel, N., Kaiser, F. K., Giladi, S., Sharabi, S., Moyal, R., Shpolyansky, S., Murillo, A., Elyashar, A., and Puzis, R. (2025). Labeling network intrusion detection system (nids) rules with mitre att&ck techniques: Machine learning vs. large language models. *Big Data and Cognitive Computing*, 9(2):23.
- Feng, Y. and Sakurai, K. (2025). Network intrusion detection: Evolution from conventional approaches to llm collaboration and emerging risks. *arXiv preprint arXiv:2510.23313*.
- Habibzadeh, A., Feyzi, F., and Atani, R. E. (2025). Large language models for security operations centers: A comprehensive survey. *arXiv preprint arXiv:2509.10858*.
- Han, Z., Gao, C., Liu, J., Zhang, J., and Zhang, S. Q. (2024). Parameter-efficient fine-tuning for large models: A comprehensive survey. *arXiv preprint arXiv:2403.14608*.
- Hu, T. and Zhou, X.-H. (2024). Unveiling llm evaluation focused on metrics: Challenges and solutions. *arXiv preprint arXiv:2404.09135*.
- Meng, F., Gui, J., Li, Y., and Wu, Y. (2025). Rhino: Guided reasoning for mapping network logs to adversarial tactics and techniques with large language models. *arXiv preprint arXiv:2510.14233*.
- Mitra, S., Bazarov, A., Duclos, M., Mittal, S., Piplai, A., Rahman, M. R., Ziegler, E., and Rahimi, S. (2025). Falcon: Autonomous cyber threat intelligence mining with llms for ids rule generation. *arXiv preprint arXiv:2508.18684*.
- Sconzo, M. (2025). Security repo: Samples of security related data. https://www.secrepo.com/tg/tg_snort_full.7z. Licensed under CC BY 4.0.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017). Attention is all you need.

Yuan, D., Rastogi, E., Zhao, F., Goyal, S., Naik, G., and Rajagopal, S. P. (2024). Evaluate summarization in fine-granularity: Auto evaluation with llm. *arXiv preprint arXiv:2412.19906*.